


Procesarea Imaginilor Digitale

Curs - Thresholding


Universitatea "Transilvania" din Braşov



- transformă o imagine în tonuri de gri într-o imagine binară, de exemplu pe baza unui prag - *threshold* - t
- partizionează imaginea în obiecte (zone de interes) și fundal (zone care nu ne interesează).


$$T(r) = \begin{cases} 0, & r \leq t \\ 255, & r > t \end{cases}$$

Segmentare cu două praguri



$$T(r) = \begin{cases} 0, & r \leq t_1 \\ 255, & t_1 < r \leq t_2 \\ 0, & r > t_2 \end{cases}$$

Segmentare cu două praguri



$$T(r) = \begin{cases} 0, & r \leq t_1 \\ l_1, & t_1 < r \leq t_2 \\ l_2, & r > t_2 \end{cases}$$

Cele mai simple metode de selectare a unui prag global automat:

- Pe baza mediei aritmetice: $t = \text{mean}(f)$

- Prag **mid-range**:

$$t = \text{round} \left(\frac{\max(f) + \min(f)}{2} \right)$$

- **Quantile threshold** - presupune faptul că se poate estima procentul b al pixelilor de fundal în raport cu numărul total de pixeli


$$t = \min \left\{ j \left| \sum_{k=0}^j n_k \geq n * b \right. \right\}$$

unde n_k = nr de pixeli de culoarea k , n = nr de pixeli din imagine.


Thresholding - Prag global automat



Imagine originală




Histogramă imagine originală



Average Threshold



Mid-range Threshold



Quantile Threshold (85%)

- Calculul unui prag automat are la bază proprietăți statistice ale imaginii
- Histograma relativă: $h : \{0, 1, \dots, 255\} \rightarrow [0, 1]$, $h(k) = n_k/n$, n_k = numărul de pixeli de nivel k .
 - - poate fi considerată funcție de repartiție a nivelurilor de gri
 - - Notăm $p(k) := h(k)$ - probabilitatea de apariție a unui anumit nivel de gri în imagine

Proprietăți statistice ale unui set de date

Se consideră un set de date $\{x_1, x_2, \dots, x_k\}$

- **Media:**

$$\mu = \frac{1}{k} \sum_{j=1}^k x_j$$

- **Varianța / Dispersia:**

$$\sigma^2 = \frac{1}{k} \sum_{j=1}^k (x_j - \mu)^2$$

- **Abaterea standard / Deviația standard:**

$$\sigma = \sqrt{\frac{1}{k} \sum_{j=1}^k (x_j - \mu)^2}$$

Fie p funcția de probabilitate pentru nivelurile de gri ale imaginii, atunci pentru pixelii din intervalul $[t_1, t_2]$:

- **Media:**

$$\mu_{[t_1, t_2]} = \frac{\sum_{k=t_1}^{t_2} kp(k)}{\sum_{k=t_1}^{t_2} p(k)} \Rightarrow \mu = \sum_{k=0}^{255} kp(k)$$

- **Varianța:**


$$\sigma_{[t_1, t_2]}^2 = \frac{\sum_{k=t_1}^{t_2} (k - \mu_{[t_1, t_2]})^2 p(k)}{\sum_{k=t_1}^{t_2} p(k)} \Rightarrow \sigma^2 = \sum_{k=0}^{255} (k - \mu)^2 p(k) = \sum_{k=0}^{255} k^2 p(k) - \mu^2$$

Q2_1: Care dintre cele două imagini de mai jos are varianța mai mare?

Ambele imagini au aceeași dimensiune 64×64 . În imaginea din stânga ambele dungii au aceeași grosime. Culoarele sunt 64 și 190. În imaginea din dreapta avem pătrate identice ca dimensiune. Culoarele sunt 64 și 190.




a)



b)

Q2_2: Se consideră imaginea de mai jos.
Calculați media și varianța pe baza
histogramei.



Pătratul 1: 10×10 , culoarea 200

Pătratul 2: 5×5 , culoarea 160

Pătratul 3: 3×3 , culoarea 80

$$\mu_{[t_1, t_2]} = \frac{\sum_{k=t_1}^{t_2} kp(k)}{\sum_{k=t_1}^{t_2} p(k)}$$

$$\sigma_{[t_1, t_2]}^2 = \frac{\sum_{k=t_1}^{t_2} (k - \mu_{[t_1, t_2]})^2 p(k)}{\sum_{k=t_1}^{t_2} p(k)}$$

Algoritm iterativ: Partiționarea pixelilor în două clase C_1 (regiunea de interes) și C_2 (fundalul) pe baza pragului global t

- 1 Selectează un prag inițial t_0 (ex. media nivelelor de gri);

Algoritm iterativ: Partiționarea pixelilor în două clase C_1 (regiunea de interes) și C_2 (fundalul) pe baza pragului global t

- 1 Selectează un prag inițial t_0 (ex. media nivelelor de gri);
- 2 La pasul k partiționează imaginea pe baza lui t_k în C_1 - toți pixelii $> t_k$ - și C_2 - toți pixelii $\leq t_k$;

Algoritm iterativ: Partiționarea pixelilor în două clase C_1 (regiunea de interes) și C_2 (fundalul) pe baza pragului global t


- 1 Selectează un prag inițial t_0 (ex. media nivelelor de gri);
- 2 La pasul k partiționează imaginea pe baza lui t_k în C_1 - toți pixelii $> t_k$ - și C_2 - toți pixelii $\leq t_k$;
- 3 Calculează mediile μ_1 și μ_2 pentru C_1 și respectiv C_2 (folosind histograma normalizată);

Algoritm iterativ: Partiționarea pixelilor în două clase C_1 (regiunea de interes) și C_2 (fundalul) pe baza pragului global t

- 1 Selectează un prag inițial t_0 (ex. media nivelelor de gri);
- 2 La pasul k partiționează imaginea pe baza lui t_k în C_1 - toți pixelii $> t_k$ - și C_2 - toți pixelii $\leq t_k$;
- 3 Calculează mediile μ_1 și μ_2 pentru C_1 și respectiv C_2 (folosind histograma normalizată);
- 4 Calculează $t_{k+1} = \frac{\mu_1 + \mu_2}{2}$;

Algoritm iterativ: Partiționarea pixelilor în două clase C_1 (regiunea de interes) și C_2 (fundalul) pe baza pragului global t

- 1 Selectează un prag inițial t_0 (ex. media nivelelor de gri);
- 2 La pasul k partiționează imaginea pe baza lui t_k în C_1 - toți pixelii $> t_k$ - și C_2 - toți pixelii $\leq t_k$;
- 3 Calculează mediile μ_1 și μ_2 pentru C_1 și respectiv C_2 (folosind histograma normalizată);
- 4 Calculează $t_{k+1} = \frac{\mu_1 + \mu_2}{2}$;
- 5 Repetă pașii 2 - 4 până când $t_{k+1} = t_k$.



$t = 83$

Prag global optimal - prag t care optimizează o anumită funcție obiectiv
Pragul partiționează pixelii în două clase: fond - obiect(e)

Metoda Otsu - minimizează eroarea de clasificare a unui pixel prin maximizarea raportului varianță inter-clasă / varianță intra-clasă

Algoritmul pragului de eroare minimă (Minimum error threshold) - minimizează o funcție de eroare de clasificare

Algoritmul de maximizare a entropiei - maximizează funcția de entropie calculată pe baza celor două clase considerate

Problematică

Partiționarea pixelilor în două clase - C_1 (fundal) și C_2 (obiect), pe baza unui prag t

Problematică

Partiționarea pixelilor în două clase - C_1 (fundal) și C_2 (obiect), pe baza unui prag t

Prag bun

- “indivizii” unei clase sunt cât mai asemănători $\Rightarrow$ varianța mică în interiorul clasei.
- cele două clase - cât mai diferite $\Rightarrow$ “centrale” (date prin medii) cât mai depărtate.

Problematică

Partiționarea pixelilor în două clase - C_1 (fundal) și C_2 (obiect), pe baza unui prag t

Prag bun

- “indivizii” unei clase sunt cât mai asemănători $\Rightarrow$ varianța mică în interiorul clasei.
- cele două clase - cât mai diferite $\Rightarrow$ “centrele” (date prin medii) cât mai depărtate.

Ce ne trebuie

Proprietăți statistice ale celor două clase (care depind de t).

Proprietățile statistice - clasa C_1	Proprietățile statistice - clasa C_2
Probabilitatea apartenenței la C_1 $P_1(t) = \sum_{k=0}^t p(k)$	Probabilitatea apartenenței la C_2 $P_2(t) = \sum_{k=t+1}^{255} p(k)$
Media $\mu_1(t) = \frac{1}{P_1(t)} \sum_{k=0}^t kp(k)$	$\mu_2(t) = \frac{1}{P_2(t)} \sum_{k=t+1}^{255} kp(k)$
Varianța $\sigma_1^2(t) = \frac{1}{P_1(t)} \sum_{k=0}^t (k - \mu_1(t))^2 p(k)$	$\sigma_2^2(t) = \frac{1}{P_2(t)} \sum_{k=t+1}^{255} (k - \mu_2(t))^2 p(k)$

$p(k)$ - probabilitatea nivelului k , dată prin histograma normalizată

Obs: $P_1(t) + P_2(t) = 1, \forall t \in [0, 255]$

Varianța inter-clase (*between-class variance*) este definită prin:

$$\begin{aligned}\sigma_B^2(t) &= P_1(t) (\mu_1(t) - \mu)^2 + P_2(t) (\mu_2(t) - \mu)^2 = \\ &= P_1(t)P_2(t) (\mu_1(t) - \mu_2(t))^2\end{aligned}$$

unde

$$\mu = \sum_{k=0}^{255} kp(k) = P_1(t)\mu_1(t) + P_2(t)\mu_2(t)$$

este media nivelelor de gri pentru întreaga imagine.

Varianța inter-clase (*between-class variance*) este definită prin:

$$\begin{aligned}\sigma_B^2(t) &= P_1(t) (\mu_1(t) - \mu)^2 + P_2(t) (\mu_2(t) - \mu)^2 = \\ &= P_1(t)P_2(t) (\mu_1(t) - \mu_2(t))^2\end{aligned}$$

unde

$$\mu = \sum_{k=0}^{255} kp(k) = P_1(t)\mu_1(t) + P_2(t)\mu_2(t)$$

este media nivelelor de gri pentru întreaga imagine.

Varianța intra-clase (*within-class variance*) este definită prin:

$$\sigma_W^2(t) = P_1(t)\sigma_1^2(t) + P_2(t)\sigma_2^2(t)$$

Pragul optimal: prag care maximizează raportul

$$\eta = \frac{\sigma_B^2(t)}{\sigma_W^2(t)}$$

Varianța totală pentru imagine:


$$\sigma^2 = \sum_{k=0}^{255} (k - \mu)^2 p(k) = \sigma_B^2(t) + \sigma_W^2(t)$$

Rezultă: $\sigma_B^2(t)$ crește $\Rightarrow \sigma_W^2(t)$ scade.

Practic:


- calculează $\sigma_B^2(t)$ pentru fiecare prag $0 < t < 255$
- selectează acel t care maximizează $\sigma_B^2(t)$
- dacă maximul se obține pentru mai mult de o singură valoare, atunci pragul optim se consideră a fi media diferitelor valori pentru care s-a obținut acest maxim.

Prag global optimal - *Otsu* - Exemple




$t = 83$

Prag global optimal - *Otsu* - Exemple





$t_{Intermeans} = 118$



$t_{Otsu} = 150$

Prag global optimal - Eroare minimă - *Minimum Error Threshold*

Idee: se presupune cele două clase C_1 și C_2 pot fi reprezentate prin 2 repartiții Gaussiene.



Idee: se presupune cele două clase C_1 și C_2 pot fi reprezentate prin 2 repartiții Gaussiene.

Deci: $P(k|C_i)$ = probabilitatea ca valoarea k să apară în clasa C_i e dată de repartiția Gauss

$$P(k|C_i) = \frac{1}{\sqrt{2\pi}\sigma_i} e^{\frac{-(k-\mu_i)^2}{2\sigma_i^2}}$$

unde μ_i - media valorilor și σ_i^2 - varianța din clasa C_i , $i = 1, 2$

Scop: clasificarea pixelilor - dacă găsesc valoarea $k \Rightarrow$ face parte din C_1 sau din C_2 ?

Ne interesează:

- $P(C_1|k)$ - probabilitatea ca să fie clasa C_1 , dacă s-a găsit valoarea k
- $P(C_2|k)$ - probabilitatea ca să fie clasa C_2 , dacă s-a găsit valoarea k

$$P(C_i|k) = \frac{P(k|C_i)P(C_i)}{p(k)}$$

Decizie Bayesiană: dacă $P(C_1|k) > P(C_2|k) \Rightarrow$ atribui k clasei C_1 , altfel atribui clasei C_2

Se minimizează riscul de a face o clasificare greșită.

$$P(C_1|k) > P(C_2|k) \Leftrightarrow \frac{P(k|C_1)P(C_1)}{p(k)} > \frac{P(k|C_2)P(C_2)}{p(k)}$$

Putem renunța la termenul $p(k)$ în inegalitate. Înlocuim $P(k|C_i)$ și obținem:

$$P(k|C_i)P(C_i) = \frac{1}{\sqrt{2\pi}\sigma_i} e^{\frac{-(k-\mu_i)^2}{2\sigma_i^2}} P(C_i)$$

Vrem:

- $P(C_1|k)$ cât mai mare pentru valorile din clasa C_1 și cât mai mică pentru valorile din clasa C_2 și similar

$$P(C_1|k) > P(C_2|k) \Leftrightarrow \frac{P(k|C_1)P(C_1)}{p(k)} > \frac{P(k|C_2)P(C_2)}{p(k)}$$

Putem renunța la termenul $p(k)$ în inegalitate. Înlocuim $P(k|C_i)$ și obținem:

$$P(k|C_i)P(C_i) = \frac{1}{\sqrt{2\pi}\sigma_i} e^{\frac{-(k-\mu_i)^2}{2\sigma_i^2}} P(C_i)$$

Vrem:

- $P(C_1|k)$ cât mai mare pentru valorile din clasa C_1 și cât mai mică pentru valorile din clasa C_2 și similar
- $P(C_2|k)$ cât mai mare pentru valorile din clasa C_2 și cât mai mică pentru valorile din clasa C_1

$$P(k|C_i)P(C_i) = \frac{1}{\sqrt{2\pi}\sigma_i} e^{\frac{-(k-\mu_i)^2}{2\sigma_i^2}} P(C_i)$$

Funcția Logaritm este crescătoare $\Rightarrow$ putem să o aplicăm formulei fără să schimbăm inegalitatea:

$$\begin{aligned} \ln(P(k|C_i)P(C_i)) &= \ln\left(\frac{1}{\sqrt{2\pi}\sigma_i}\right) + \ln\left(e^{\frac{-(k-\mu_i)^2}{2\sigma_i^2}}\right) + \ln(P(C_i)) = \\ &= -\frac{1}{2} \left[\ln(2\pi) + \frac{(k-\mu_i)^2}{\sigma_i^2} + \ln(\sigma_i^2) - 2\ln(P(C_i)) \right] \end{aligned}$$

$$-\frac{1}{2} \left[\ln(2\pi) + \frac{(k - \mu_i)^2}{\sigma_i^2} + \ln(\sigma_i^2) - 2\ln(P(C_i)) \right]$$

- Valoarea acestei expresii trebuie să fie cât mai mare pentru un pixel k din clasa C_i

$$-\frac{1}{2} \left[\ln(2\pi) + \frac{(k - \mu_i)^2}{\sigma_i^2} + \ln(\sigma_i^2) - 2\ln(P(C_i)) \right]$$

- Valoarea acestei expresii trebuie să fie cât mai mare pentru un pixel k din clasa C_i
- $\ln(2\pi)$ este constantă, deci poate fi ignorată din relația care trebuie maximizată.

$$-\frac{1}{2} \left[\ln(2\pi) + \frac{(k - \mu_i)^2}{\sigma_i^2} + \ln(\sigma_i^2) - 2\ln(P(C_i)) \right]$$

- Valoarea acestei expresii trebuie să fie cât mai mare pentru un pixel k din clasa C_i
- $\ln(2\pi)$ este constantă, deci poate fi ignorată din relația care trebuie maximizată.
- În loc să maximizăm relația de mai sus este suficient să minimizăm:

$$\epsilon_i(k) = \frac{(k - \mu_i)^2}{\sigma_i^2} + \ln(\sigma_i^2) - 2\ln(P(C_i))$$

$\epsilon_i(k)$ = măsura potențialei erori de clasificare a valorii observate k în clasa C_i .

Valorile $\mu_1, \mu_2, \sigma_1, \sigma_2$ sunt determinate de pragul de binarizare t , care împarte valorile de gri în clasele C_1 și C_2 .

Calitatea clasificării pe baza pragului t poate fi estimată pe baza funcției

$$e(t) = \sum_{k=0}^t p(k)\epsilon_1(k) + \sum_{k=t+1}^{255} p(k)\epsilon_2(k)$$

Din calcule matematice, formula de mai sus devine:




$$e(t) = 1 + P_1(t) \ln(\sigma_1^2(t)) + P_2(t) \ln(\sigma_2^2(t)) - 2P_1(t) \ln(P_1(t)) - 2P_2(t) \ln(P_2(t))$$

Care trebuie minimizată.



Algoritm

- ① Inițializează ϵ_{min}
- ② Pentru fiecare prag $t \in [0, 255]$
 - calculează $P_1, P_2 = 1 - P_1, \mu_1, \mu_2, \sigma_1^2, \sigma_2^2$ pe baza histogramei relative
 - calculează $\epsilon = 1 + P_1 \ln(\sigma_1^2) + P_2 \ln(\sigma_2^2) - 2P_1 \ln(P_1) - 2P_2 \ln(P_2)$
- ③ dacă $\epsilon < \epsilon_{min}$ atunci $\epsilon_{min} \leftarrow \epsilon$ și reține pragul curent
- ④ returnează pragul pentru care s-a obținut cea mai mică valoarea a lui ϵ

Prag global optimal - Eroare minimă - *Minimum Error Threshold*



Prag global optimal - Eroare minimă - *Minimum Error Threshold*



Metoda Otsu - Praguri multiple

Metoda Otsu poate fi extinsă pentru un număr variabil - $(K - 1)$ - de praguri: $t_1, t_2, \dots, t_{K-1}$ care determină K clase $C_1, C_2, \dots, C_K$

Varianța inter-clasă devine:

$$\sigma_B^2 = \sum_{i=1}^K P_i (\mu_i - \mu)^2$$

unde C_i = clasa pixelilor din intervalul $(t_{i-1}, t_i]$

$$P_i = \sum_{k=t_{i-1}+1}^{t_i} p(k)$$

și

$$\mu_i = \frac{1}{P_i} \sum_{k=t_{i-1}+1}^{t_i} kp(k)$$

Se vor alege acele praguri $t_1 < t_2 < \dots < t_{K-1}$ care maximizează σ_B

Exemplu Pentru 3 clase - 2 praguri t_1 și t_2

Varianța inter-clasă devine:

$$\sigma_B^2 = P_1(\mu_1 - \mu)^2 + P_2(\mu_2 - \mu)^2 + P_3(\mu_3 - \mu)^2$$



Pentru clasa C_1	Pentru clasa C_2	Pentru clasa C_3
$P_1 = \sum_{k=0}^{t_1} p(k)$	$P_2 = \sum_{k=t_1+1}^{t_2} p(k)$	$P_3 = \sum_{k=t_2+1}^{255} p(k)$
$\mu_1 = \frac{1}{P_1} \sum_{k=0}^{t_1} kp(k)$	$\mu_2 = \frac{1}{P_2} \sum_{k=t_1+1}^{t_2} kp(k)$	$\mu_3 = \frac{1}{P_3} \sum_{k=t_2+1}^{255} kp(k)$

Se vor alege acele praguri $0 < t_1 < t_2 < 255$ care maximizează σ_B^2

Algoritm - pentru 2 praguri



- 1 se pornește cu $\sigma_B^2\text{-max} = 0$
- 2 $t_1 = 1$
- 3 pentru $t_2 = t_1 + 1 \dots 254$ execută pașii
- 4 calculează $P_1, P_2, P_3, \mu_1, \mu_2, \mu_3$ și σ_B^2
- 5 dacă $\sigma_B^2 > \sigma_B^2\text{-max}$ atunci $\sigma_B^2\text{-max} \leftarrow \sigma_B^2$
- 6 $t_1 = t_1 + 1$
- 7 dacă $t_1 < 253$ mergi la pasul 3

Metoda Otsu - Praguri multiple - Exemplu




$$t_1 = 97, t_2 = 160$$

Metoda Otsu - Praguri multiple - Exemplu



$$t_1 = 91, t_2 = 181$$

Extragerea fundalului - Metoda triunghiului



- Se caută valoarea maximă din histogramă
- Se caută "extrema" histogramei (nivelul de culoare minim/maxim prezent în imagine) cât mai departe de poziția maximului (poate fi de o parte sau de alta a maximului).
- Se consideră latura BC care "unește" maximul de minim
- Se alege ca prag t acea valoare k pentru care se obține cea mai mare distanță dintre $H[k]$ și $BC + decalaj$

Extragerea fundalului - Metoda triunghiului - Exemplu

Anweisungsbeispiele

GOTO 200

GOTO *FIN


ON M1 GOTO 100, 200, 300

Anweisungsbeispiele

GOTO 200

GOTO *FIN

ON M1 GOTO 100, 200, 300



- se utilizează în cazul iluminării neuniforme.
- calculează pentru diferite regiuni praguri diferite prin
 - partiționarea imaginii în subimagini disjuncte și calculul unui prag pentru fiecare subimagine
 - calcularea pentru fiecare pixel (x, y) a unui prag pe baza proprietăților statistice ale unei vecinătăți

1 Metoda lui *Bernsen*:

$$t_{xy} = (\max_{xy} + \min_{xy})/2$$

Obs: Dacă $\max_{xy} - \min_{xy} < t_{min}$,
atunci regiunea se consideră uniformă.

Dacă notăm cu S_{xy} o vecinătate centrată
în pixelul (x, y) atunci:

- t_{xy} = pragul pentru pixelul (x, y)
- μ_{xy} - media pixelilor din S_{xy}
- $\min_{xy}$, $\max_{xy}$, valoarea minimă
respectiv maximă din S_{xy}
- σ_{xy}^2 - varianța pixelilor din S_{xy}

1 Metoda lui *Bernsen*:

$$t_{xy} = (\max_{xy} + \min_{xy})/2$$

Obs: Dacă $\max_{xy} - \min_{xy} < t_{min}$,
atunci regiunea se consideră uniformă.

2 Metoda lui *Niblak*:

$$t_{xy} = \mu_{xy} + k\sigma_{xy}^2 + d, \quad 0 < k \leq 1$$

d - constantă care stabilizează
segmentarea, când regiunea este
aproape uniformă.

Dacă notăm cu S_{xy} o vecinătate centrată
în pixelul (x, y) atunci:

- t_{xy} = pragul pentru pixelul (x, y)
- μ_{xy} - media pixelilor din S_{xy}
- $\min_{xy}$, $\max_{xy}$, valoarea minimă
respectiv maximă din S_{xy}
- σ_{xy}^2 - varianța pixelilor din S_{xy}

1 Metoda lui *Bernsen*:

$$t_{xy} = (\max_{xy} + \min_{xy})/2$$

Obs: Dacă $\max_{xy} - \min_{xy} < t_{min}$,
atunci regiunea se consideră uniformă.

2 Metoda lui *Niblak*:

$$t_{xy} = \mu_{xy} + k\sigma_{xy}^2 + d, 0 < k \leq 1$$

d - constantă care stabilizează
segmentarea, când regiunea este
aproape uniformă.

3 Binarizare adaptivă în timp real:

$$t_{xy} = b\mu_{xy}$$

Dacă notăm cu S_{xy} o vecinătate centrată
în pixelul (x, y) atunci:

- t_{xy} = pragul pentru pixelul (x, y)
- μ_{xy} - media pixelilor din S_{xy}
- $\min_{xy}$, $\max_{xy}$, valoarea minimă
respectiv maximă din S_{xy}
- σ_{xy}^2 - varianța pixelilor din S_{xy}

Prag adaptabil pentru fiecare pixel - Exemplu

[illegible]

seems to have some difficulty enhancing image in underexposed and overexposed regions. The luminance division in the darker regions is insufficient and unsharp edges and halo artifacts are introduced which caused bigger error. The edge enhancement method in the proposed method only uses information in highlight regions to have the "strong" or "artificial" and enlarge the block effect. However, the method processes more details with high visual quality to transform lighting conditions than ALMF. Just as discussed in Fig. 10, the histogram shows the characteristics of the image. The edge enhancement method in the proposed method (a) shows that the shadow region in the original image shifts to the better luminance range, and the sky region almost unchanged, for more displayed results, the proposed method restores local details and global contrast. Especially for degraded images in format of .jpg, our method does not modify the file extension and the method can be used in the situation of various objective statistical methods in Table 1.

Figure 2 and Figure 3. It is difficult to enhance images with the luminance enhancement method. The luminance enhancement method is insufficient and unstable. The method which caused brightening in the shadow region is easy to brighten overexposed areas. The highlight regions to have the maximum average block effect. However, the proposed method deals with high visual quality in the shadow region. As discussed in the next section, the characteristic of the image is that the shadow region is the original image shift in the better luminance range, and the sky region almost unchanged, for more displayed results, the proposed method removes local details and global contrast. Especially for degraded images in form of jpg, our method does not amplify the block effect but improves the image quality. The visual values of objective standards are listed in Table 1.

Figure 2 and Figure 4. It is difficult to enhance image contrast in the shadow region. The luminance is insufficient and unsmooth. The shadow region is not as bright as the highlight region, so it is easy to brighten the shadow region. However, this will highlight regions to have the same black effect. However, the proposed method can enhance details with high visual quality. The proposed method is different than ALMF. Just as discussed in the introduction, the proposed method shows the characteristics of the strong shadow region. The proposed method can be generalized to the shadow region in the original image. Figure 5 shows that the shadow region in the original image (left) is the bottom luminance range, and the sky region also changed, for more deployed results, the proposed method can enhance local details and global contrast. Especially for degraded images in format of jpg, our method does not amplify the block effect badly. The experimental results and visualizations, values of objective metrics are listed in Table 1.

shown in Figure 2 and Figure 3. For the RCR, it seems to have some difficulty enhancing images in underexposed and overexposed regions. The luminance taken in the darker regions is insufficient and unsharp edges and halo artifacts are introduced which caused bigger damage. For the proposed method, the proposed method can easily losing information in highlight regions to have the 'bleeding out' artifact and enlarge the block effect. However, the proposed method possesses more details with high visual quality in uniform lighting conditions than ALMF. Just as discussed in [6], the histogram shows the characteristics of the image. For the histogram, the proposed method has the following advantages: (i) shows that the shadow region in the original image shifts to the better luminance range, and the sky region almost unchanged, less more complicated results, the proposed method can remove local details and global contrast. Especially for the degraded images in format of jpg, our method does not have any loss of image quality. The experimental results of the histogram values of objective measures are listed in Table 1.

shown in Figure 2 and Figure 4. For SRCR, it seems to have some difficulty enhancing image contrast in underexposed and overexposed regions. The luminance in the darker regions is insufficient and saturation is low and false artifacts are introduced which caused ghosting. The original image is shown in Figure 5. The proposed method loses information in highlight regions to have a "blowing out" artifact and enlarges the block effect. However, the method possesses more details with high visual quality than uniform lighting conditions than ALMF. Just as discussed in [15], the brightness alters the characteristics of the image. Figure 6 shows the shadow region in the original image (a) is the better luminance range, and the sky region also changed, far more displayed results, the proposed method can restore local details and global contrast. Especially for degraded images in format of jpg, our method does not lose the original image's color and contrast. The experimental results of selective sharpening are listed in Table 1.

[illegible]

ALMF seems to have some difficulty enhancing image in underexposed and overexposed regions. The luminance reduction in the darker regions is insufficient and unsharp edges and halos are still introduced with increased contrast. The original ALMF is not able to bring out the low spatial frequency information in highlight regions to have the 'eying out' artifact and enlarge the block effect. However, the method proposed herein details with high visual quality in uniform lighting conditions than ALMF. Just as discussed in [9], the algorithm shows the characteristics of image contrast probability based on the contrast probability of the image. Figure 10 shows that the shadow region in the original image shifts to the better luminance range, and the sky region almost unchanged. For more detailed results, the proposed method removes local details and global contrast. Especially, the degraded images in the form of jpg, our method does not modify the bit stream of the original image. The experimental values of objective standards are listed in Table 1.

[illegible]

difficultly enhancing image contrast in the degraded regions. The luminance contrast is insufficient and unsaturated, which caused bigger brightness overexposure. In order to have the better image quality, the proposed method is discussed. The results of the image enhancement are shown in Fig. 10. Figure 10(a) is the original image shifted to the better luminance range. The degraded region almost changed, for more details, the proposed method is used to restore local details and increase contrast. Especially, since degraded images in format of jpg, our method does not amplify the block effect badly. Besides, in the degraded situation, values of objective standards are listed in Table 1.

[illegible]

regions as shown in Figure 2 and Figure 3. For RCR, it seems to have some difficulty enhancing image in underexposed and overexposed regions. The luminance relation in the darker regions is insufficient and unrealistic for human vision. The contrast introduced by the contrast enhancement of the original ALM image in the underexposed region is insufficient in highlight regions to have a 'popping out' artifact and enlarge the black effect. However, the method possesses more details with high visual quality in uniform lighting conditions than ALM. Just as discussed in [6], the integration across the characteristics of the image is a very important factor in image enhancement. Figure 4 shows that the shadow region in the original image shifts to the better luminance range, and the sky region almost changed, for more deployed results, the proposed method can restore local details and global contrast. Especially for degraded images in format of jpg, our method can greatly improve the image quality. The experimental results, values of objective standards are listed in Table 1.

a) Original Image

b) Otsu threshold

c) Adaptive Threshold

Figure: Thresholding adaptiv utilizând formula $t_{xy} = b\mu_{xy}$ cu $b = 0.8$.

Calcul rapid al mediei într-o vecinătate - Imaginea integrală

Problemă: pentru fiecare pixel (x, y) al unei imagini $M \times N$ trebuie calculată media pixelilor într-o vecinătate $dim \times dim$.

Ce complexitate avem?

Calcul rapid al mediei într-o vecinătate - Imaginea integrală

Problemă: pentru fiecare pixel (x, y) al unei imagini $M \times N$ trebuie calculată media pixelilor într-o vecinătate $dim \times dim$.

Ce complexitate avem?

$$\text{Complexitatea} = O(M * N * dim^2)$$

Calcul rapid al mediei într-o vecinătate - Imaginea integrală

Imaginea integrală: Considerăm imaginea $f(x, y)$, atunci $I(x, y)$ este dată prin:

$$I(x, y) = \sum_{s=0}^x \sum_{t=0}^y f(s, t)$$

1	2	2	4	3	2	4
4	4	1	2	3	4	4
2	2	2	3	1	1	2
1	2	1	1	3	3	4
3	2	2	3	3	1	2
3	3	3	4	3	3	4
1	2	1	1	2	2	4

Imaginea originală

1	3	5	9	12	14	18
5	11	14	20	26	32	40
7	15	20	29	36	43	53
8	18	24	34	44	54	68
11	23	31	44	57	68	84
14	29	40	57	73	87	107
15	32	44	62	80	96	120

Imaginea integrală

Imaginea integrală - calcul bazat pe formule de recurență

$$I(x, y) = \begin{cases} f(0, 0), & \text{pentru } x = 0, y = 0 \\ I(0, y - 1) + f(0, y), & \text{pentru } x = 0 \\ I(x - 1, 0) + f(x, 0), & \text{pentru } y = 0 \\ I(x - 1, y) + I(x, y - 1) - I(x - 1, y - 1) + f(x, y), & \text{altfel} \end{cases}$$

1	2	2	4	3	2	4
4	4	1	2	3	4	4
2	2	2	3	1	1	2
1	2	1	1	3	3	4
3	2	2	3	3	1	2
3	3	3	4	3	3	4
1	2	1	1	2	2	4

Imaginea originală

1	3	5	9	12	14	18
5	11	14	20	26	32	40
7	15	20	29	36	43	53
8	18	24	34	44	54	68
11	23	31	44	57	68	84
14	29	40	57	73	87	107
15	32	44	62	80	96	120

Imaginea integrală

Calculul sumei unei vecinătăți cu imaginea integrală - complexitate $M \times N$

$$sum(x_0, y_0, x_1, y_1) = \begin{cases} A, & \text{pentru } x_0 = 0, y_0 = 0 \\ A - B, & \text{pentru } y_0 = 0 \\ A - D, & \text{pentru } x_0 = 0 \\ A + C - B - D, & \text{altfel} \end{cases}$$

unde $A = I(x_1, y_1)$, $B = I(x_0 - 1, y_1)$, $C = I(x_0 - 1, y_0 - 1)$, $D = I(x_1, y_0 - 1)$.

Imaginea originală

		x_0 x_1			
		1	2	2	4
		4	4	1	2
y_0		2	2	2	3
		1	2	1	1
y_1		3	2	2	3
		3	3	3	4
		1	2	1	1

sum = 19

Imaginea integrală

		x_0 x_1			
		1	3	5	9
		5	11	14	20
y_0		7	15	20	29
		8	18	24	34
y_1		11	23	31	44
		14	29	40	57
		15	32	44	62

sum = $A + C - B - D = 57 + 11 - 23 - 26 = 19$


		x_0 x_1			
y_0					
y_1					

Problematică:

- Obținerea unui obiect / zone de interes pornind de la o imagine color
- Depinde de cerința dată

Binarizarea imaginilor color

Obținerea unui obiect de interes pe un fundal relativ uniform:



Binarizarea imaginilor color


Binarizarea pe baza culorii = identificarea regiunilor / obiectelor cu o anumită culoare



Grayscale




Binarizare
după culoare



Otsu




Binarizarea imaginilor color



Fiecare culoare: un vector (R, G, B)

Ce înseamnă că două culori (R_1, G_1, B_1) și (R_2, G_2, B_2) sunt asemănătoare?



Culori asemănătoare

- $c(x, y) = (R(x, y), G(x, y), B(x, y))$ - culoarea pixelului (x, y) ;
- $c_0 = (R_0, G_0, B_0)$ - culoarea de referință;
- t - pragul care definește asemănarea.

$c(x, y)$ este asemănătoare cu c_0 dacă:

$$d := \sqrt{(R(x, y) - R_0)^2 + (G(x, y) - G_0)^2 + (B(x, y) - B_0)^2} \leq t$$


Reprezentarea 2D a cubului de culoare normalizat


Pentru fiecare pixel (x, y) de culoare $(R(x, y), G(x, y), B(x, y))$:

$$r(x, y) = \frac{R(x, y)}{R(x, y) + G(x, y) + B(x, y)}$$

$$g(x, y) = \frac{G(x, y)}{R(x, y) + G(x, y) + B(x, y)}$$

$$\begin{aligned} b(x, y) &= \frac{B(x, y)}{R(x, y) + G(x, y) + B(x, y)} = \\ &= 1 - r(x, y) - g(x, y) \end{aligned}$$





Culori asemănătoare utilizând tabloul cromatic

- $r(x, y), g(x, y)$ - valorile normalizate ale componentelor R și G ale pixeului (x, y) ;
- (r_0, g_0) - valorile normalizate ale componentelor R și G pentru culoarea de referință;
- t - pragul care definește asemănarea.


$c(x, y)$ este asemănătoare cu c_0 dacă:

$$d := \sqrt{(r(x, y) - r_0)^2 + (g(x, y) - g_0)^2} \leq t$$

Exemple de binarizare



$t=0,15$



Imagine originală



Imagine binarizată 3D
 $T=30$

Imagine binarizată 2D
 $t=0,1$

Alternativă - binarizarea în spațiul de culoare HSV

- Se transformă imaginea din spațiul RGB în spațiul HSV
- Se realizează binarizarea pe canalul H în raport cu culoarea de referință

Binarizarea în spațiul de culoare HSV



Q2_3: Considerăm o imagine în spațiul de culoare *HSV*. Se dorește binarizarea relativ la culoarea roșie (i.e. toți pixelii de culoare apropiată de roșu - pe baza unui prag t - devin albi, restul devin negri).

Scrieți bucata de cod corespunzătoare, considerând că imaginea se numește *ImageHSV*.

- Binarizare
- Thresholding cu prag global automat
 - Praguri globale simple
 - Intermeans
 - Otsu
 - Minimum Error threshold
- Thresholding cu praguri multiple - ex. Otsu
- Thresholding cu prag adaptabil
- Binarizarea imaginilor color
 - Binarizare 3D
 - Diagrama cromatică
 - Binarizare 2D
 - Binarizarea în HSV